

SOFT SENSORS

Avanços em Sensoriamento Multimodal e Inteligência Artificial para Robótica e Sistemas Ciber-Físicos

Resumo— Este documento apresenta uma análise técnica de cinco publicações recentes focadas em sensoriamento avançado para robótica humanóide, atuadores macios e drones. O estudo explora métodos de percepção tátil por injeção de vibração, sensoriamento acústico ativo e fusão de dados via Filtros de Kalman e Redes Neurais (LSTM/GRU). As conclusões indicam que a transformação de estruturas físicas em "sensores computacionais" permite alta precisão (até 99%) e robustez a ruídos ambientais, superando limitações de hardware convencional.

Palavras-chave — Sensoriamento Tátil, Robótica Macia, Fusão de Sensores, UKF, LSTM/GRU, BioTac.

I. Introdução:

Este documento fornece especificações técnicas para a integração de sistemas de sensoriamento baseados em acústica, vibração e fusão de dados em plataformas robóticas avançadas. Todos os componentes essenciais, incluindo a percepção tátil por injeção de vibração, o sensoriamento acústico ativo em atuadores pneumáticos e a estimativa de torque via fusão de sensores estocástica, foram analisados por três razões: (1) facilidade de uso na implementação de feedback tátil sem a necessidade de movimentos complexos de deslizamento,, (2) conformidade automática com requisitos de segurança e estabilidade em drones e robôs humanóides,, e (3) uniformidade de métodos de processamento de sinais, variando de filtros de Kalman (UKF) a redes neurais recorrentes (LSTM/GRU),.

A evolução de robôs para tarefas complexas exige que sensores macios (soft sensors) capturem informações microscópicas, como o início do escorregamento (incipiente slip), transformando deformações em sinais de vibração propagados. Enquanto alguns componentes, como a detecção de escorregamento baseada em BioTac, utilizam injeção de ruído branco para amplificar sinais, outros sistemas utilizam microfones embutidos para "ouvir" o estado físico de atuadores pneumáticos. Adicionalmente, a predição de falhas em motores de drones por meio de aprendizado profundo (Deep Learning) garante a integridade de sistemas IoT voadores. O projetista precisará integrar esses diversos modelos computacionais, incorporando os critérios de processamento de sinais e inteligência artificial que seguem nas seções posteriores deste documento.

II. Facilidade de uso:

A. Seleção de Estruturas de Sensoriamento

A implementação de sistemas de percepção avançada exige a escolha entre métodos de sensoriamento passivos ou ativos, priorizando a simplicidade do hardware. Wall et al. demonstram que o uso de componentes de áudio comerciais, como microfones MEMS e alto-falantes de baixo custo,

permite transformar toda a estrutura de um atuador em um sensor computacional, o que elimina a necessidade de múltiplos sensores especializados,. Em cenários onde o espaço é restrito, como em procedimentos cirúrgicos ou tubulações, a injeção de vibração mecânica permite captar texturas e formas sem a necessidade de movimentos complexos de deslizamento, facilitando a aplicação em robótica com limitações geométricas,. Além disso, nota-se que esses métodos podem ser implementados de forma rápida desde que os sensores atendam às especificações básicas de vibração. Na robótica humanóide, o uso do Filtro de Kalman Inodoro (UKF) fornece um arcabouço flexível que permite estimar torques sem a necessidade de sensores físicos nas juntas, simplificando a complexidade mecânica do robô.

B. Preservação da Conformidade e Desempenho

A integridade dos sistemas robóticos é mantida através de modelos computacionais que equilibram precisão e custo de processamento. Para drones e sistemas de IoT voador, a facilidade de treinamento é um fator crítico; nesse sentido, a Unidade Recorrente Gated (GRU) destaca-se por possuir uma estrutura interna mais simples que o modelo LSTM, facilitando o aprendizado e realizando previsões aproximadamente 22,79% mais rápidas,. A robustez do sensoriamento acústico ativo também contribui para a facilidade de uso, permanecendo funcional mesmo sob ruídos ambientais de até 90 dB devido ao isolamento natural da carcaça de silicone. Adicionalmente, a conformidade do sistema de injeção de vibração é verificada pela sua capacidade de converter fenômenos microscópicos, como o início do escorregamento, em sinais macroscópicos detectáveis por um único sensor de vibração, o que simplifica drasticamente o processamento de sinais em comparação com matrizes de sensores integradas

III. METODOLOGIA

A metodologia aplicada nos estudos revisados baseia-se em uma abordagem experimental dividida em três fases:

aquisição de dados físicos por meio de transdutores avançados, processamento de sinais multimodais e interpretação computacional através de modelos de aprendizado de máquina ou estimativa estocástica.

A. Aquisição de Dados e Cenários Experimentais

A coleta de dados envolveu plataformas robóticas diversificadas para validar a eficácia dos sensores em condições reais. Em experimentos de percepção tátil e detecção de escorregamento, utilizou-se o sensor biométrico BioTac montado em braços robóticos (UR5) para interagir com objetos de diferentes texturas e materiais. Para a robótica macia, microfones MEMS e alto-falantes foram integrados a atuadores pneumáticos PneuFlex para capturar a modulação acústica sob diferentes estados físicos. Na robótica humanóide, o robô ergoCub serviu de base para coletar dados de correntes de motores e sensores inerciais distribuídos. Por fim, dados de vibração de drones foram

obtidos de motores operando a 1200 RPM em intervalos de 100 ms para simular condições normais e de falha.

B. Técnicas de Sensoriamento Ativo e Processamento de Sinais

Uma característica metodológica central em vários estudos é o sensoriamento ativo. Isso inclui a injeção de vibrações mecânicas via atuadores piezoelétricos (PZT) para magnificar fenômenos microscópicos em sinais macroscópicos e a emissão de ruído branco ou varreduras de frequência (*sweeps*) para sondar a cavidade interna de atuadores macios. Os sinais capturados (acústicos ou de vibração) são convertidos para o domínio da frequência por meio de Transformadas Rápidas de Fourier (FFT), permitindo a análise de deslocamentos de picos de ressonância como indicadores de estado. Para drones, os dados temporais brutos passam por uma normalização *min-max* antes de serem alimentados nos modelos preditivos.

C. Modelagem Computacional e Algoritmos de Estimativa

A interpretação dos dados coletados é realizada por dois tipos de arquiteturas computacionais:

1. Modelos de Aprendizado de Máquina: Utilizam-se algoritmos como SVM (Máquinas de Vetores de Suporte) e SVR (Regressão de Vetores de Suporte) para classificar texturas e estimar a razão de aderência (*stick ratio*). Modelos de vizinhos mais próximos (KNN) e perceptrons multicamadas (MLP) são empregados para regressão de forças e temperaturas. Para séries temporais complexas em drones, aplicam-se redes neurais recorrentes como LSTM e GRU.
2. Fusão de Sensores Estocástica: Em robôs humanoides, utiliza-se o Filtro de Kalman Inodoro (UKF) para fundir dados multimodais e estimar torques nas juntas sem a necessidade de sensores físicos de torque, lidando com ruídos de medição e incertezas de modelo.

D. Critérios de Avaliação e Validação

O desempenho das metodologias é validado por métricas estatísticas rigorosas. A precisão dos modelos de classificação é medida pela Taxa de Classificação Média (ACR), enquanto os modelos de regressão e predição são avaliados pelo Erro Quadrático Médio (RMSE) e pelo coeficiente de determinação (*R*). Em sistemas de controle de drones, a eficiência temporal também é um critério, comparando a velocidade de predição entre diferentes redes neurais. No caso do robô ergoCub, a validação é feita comparando o torque estimado com o rastreamento de trajetórias em espaço de junta e cartesiano sob perturbações externas

IV. RESULTADOS E DISCUSSÃO

Os resultados obtidos nas pesquisas demonstram uma evolução significativa na precisão do sensoriamento robótico multimodal e na predição de falhas via inteligência artificial.

A. Desempenho de Sensoriamento e Percepção Tátil

A implementação de injeção de vibração mecânica em sensores macios apresentou resultados superiores aos métodos tradicionais de deslizamento. Komeno e Matsubara reportaram uma acurácia de 70% na classificação de granulação de lixas e impressionantes 99% na detecção de larguras de fendas. Em sistemas de sensoriamento acústico ativo para atuadores pneumáticos, Wall et al. alcançaram uma taxa média de classificação (ACR) de 93% para seis locais de contato, com uma precisão espacial média de 3,7 mm. Além disso, a detecção de escorregamento incipiente utilizando vibração injetada superou os métodos de distribuição de pressão, especialmente nos cenários de erro extremo (piores 10% de RMSE).

B. Eficiência de Modelos de IA e Estimativa de Estado

No campo da robótica humanoide, o uso do filtro UKF permitiu o rastreamento de torque com erros RMSE extremamente baixos, variando entre 0,05 Nm e 2,5 Nm, mesmo sob perturbações externas. Quanto à predição de vibrações em drones, embora os modelos LSTM e GRU tenham apresentado métricas de precisão (*R2* e RMSE) semelhantes, o modelo GRU demonstrou ser 22,79% mais rápido na execução das predições, tornando-o ideal para aplicações de monitoramento em tempo real em sistemas de IoT voador.

C. Análise Comparativa (Tabela II)

Item	Fonte 1 e 3 (Komeno)	Fonte 2 (Wall)	Fonte 4 (Sorrentino)	Fonte 7 (Hong)
Objetivo	Percepção tátil/escorregamento	Sensoriamento acústico	Estimativa de torque	Predição de vibração
Métrica Principal	99% acurácia (fendas)	93% ACR (contato)	RMSE 0,05 - 2,5 Nm	GRU 22,79% mais rápido
Vantagem	Detecta sem deslizar	Robusto a 90 dB de ruído	Dispensa sensores de junta	Alta eficiência temporal
Limitação	Depende de PZT externo	Calibração por atuador	Estática não modelada	Foco no domínio do tempo

V. CONCLUSÃO

Resumo dos Resultados

As pesquisas analisadas confirmam que a integração de técnicas de sensoriamento ativo — seja por vibração mecânica ou acústica — permite que robôs percebam o ambiente com alta precisão (até 99%) sem a necessidade de hardware complexo ou movimentos extensivos. A fusão de dados via UKF e o uso de redes neurais recorrentes (GRU) provaram ser ferramentas eficazes para a estimativa de estados internos e predição de anomalias com baixo custo computacional.

Resposta ao Objetivo Proposto

O objetivo de analisar métodos avançados de sensoriamento foi atingido, demonstrando que a transformação de estruturas físicas em "sensores computacionais" é uma tendência viável para a robótica moderna, garantindo segurança e conformidade em drones, humanoides e atuadores macios.

Trabalhos Futuros

Recomenda-se para pesquisas futuras a investigação de representações de áudio mais complexas (como

espectrogramas) e a aplicação de modelos de IA hierárquicos para o monitoramento simultâneo de múltiplas variáveis. Além disso, a integração de segurança via *blockchain* para dados de sensores em drones e a melhoria de modelos de fricção estática em robôs humanoides são caminhos promissores.

REFERÊNCIAS

N. Komeno and T. Matsubara, "Tactile Perception based on Injected Vibration in Soft Sensor," *IEEE Robotics and Automation Letters*, vol. 6, no. 3, 2021. V. Wall, G. Zöller, and O. Brock, "Passive and Active Acoustic Sensing for Soft Pneumatic Actuators," *The International Journal of Robotics Research*, 2022. N. Komeno and T. Matsubara, "Incipient Slip Detection by Vibration Injection into Soft Sensor," *arXiv*, 2024. I. Sorrentino, G. Romualdi, and D. Pucci, "UKF-Based Sensor Fusion for Joint-Torque Sensorless Humanoid Robots," *arXiv*, 2024. J.-K. Hong, "Vibration Prediction of Flying IoT Based on LSTM and GRU," *Electronics*, vol. 11, no. 7, 2022.